基于 ARIMA 与 LSTM 模型的空气质量预测与预警

摘　要

空气污染是人类目前所面临的最严峻问题之一，其可对人体健康、生态环境等方面造成严重损害。伴随着城市化与工业化的不断深入，我国目前的污染现状愈发严重。故精确有效地对空气质量指标数据进行预测以及对未来空气状态作出预警，对生态健康、社会发展等均具有深远意义。

针对问题一，为分析得到与 PM2.5 浓度变化相关的指标因素及其对该浓度变化的影响程度，欲对所给数据进行预处理。首先对附件 1 中所给数据特点进行分析，利用多重插补对空缺值进行补全处理。再剔除附件 2 中的异常值，利用 Lagrange 插补法对其缺失值进行填充。将处理后的数据进行整合，其后，为克服数据间量纲差异过大的影响，对插补所得数据进行标准化处理。再对标准化后数据采用正态性检验，结合显著性水平与 Q-Q 图统计描述，可分析发现大部分指标数据未呈现正态分布，未在 Pearson 相关系数适用范围之内，故选用 Spearman 相关系数对各指标间的相关性进行计算和分析。最终提取出与 PM2.5 浓度较强相关的五个变量分别为 SO_2、NO_2、CO、PM10 和平均气温，再对其进行显著性检验，其结果表明 PM10 与其呈现极强相关，NO_2、CO 与其呈现强相关，SO_2、平均气温与其呈现中等程度相关。

针对问题二，为预测所给定时间段的 PM2.5 浓度，结合其历史数据的散点图特点，首先建立 ARIMA 预测模型对其进行预测，得到未来 12 天的各空气质量指标相对应的预测数据，并对其预测效果进行评价，分析得出其预测效果不佳。综合考虑后选用 LSTM 多步预测模型再对其进行预测。提取出问题一中相关性分析筛选出的五个指标作为 LSTM 模型中的输入因子，将 PM2.5 浓度设置为输出变量。将选取的指标数据导入 Python 并进行标准化处理，为防止过度拟合，选用前 80%的数据为训练集，后 20%为测试集。通过设置 LSTM 层数、神经元数量、优化器等，建立得出 LSTM 神经网络预测模型，并对测试集及其预测结果进行可视化处理。其后，通过改变预测步长，得出 3 步、5 步、7 步和 12 步预测结果的均方根误差（RMSE），其值分别为 19.4574 、21.6210、21.4685 和 22.0202。将两模型进行对比分析，最终选用拟合度更优、预测精确度更高的 LSTM 多步预测模型对未来 12 天 PM2.5 浓度进行预测，所得出的预测数据见表 6-3。对 LSTM 多步预测模型的 MAE、R^2、MAPE、残差与损失曲线进行分析，得出模型具有一定的准确性与稳健性。

针对问题三，为构建 AQI 多步预测模型，首先计算分析出 AQI 与其余各项检测指标间的 Spearman 相关系数，筛选得出 PM10、SO_2、PM2.5、NO_2 和 CO 为其主要影响因子。其后分别运用 ARIMA 模型与 LSTM 模型对未来 12 天空气质量的的 AQI 指数进行预测，自主划分训练集与预测集并将预测结果可视化，其中，LSTM 模型的均方根误差（RMSE）为 32.2989，综合评估分析得出其预测效果较好。进而，基于所得到的未来 12 天的 AQI 指数大小，分析得出其相对应的空气质量等级及预警等级，并将预警等级颜色次数进行汇总处理，上述具体结果分别见表 7-2 和表 7-3。

关键词：多重插补法　Spearman 相关系数　ARIMA 预测模型　LSTM 多步预测模型

目录

一、 问题重述 3
1.1 问题背景 3
1.2 待解决的问题 3
二、 问题分析 3
2.1 问题一的分析 3
2.2 问题二的分析 4
2.3 问题三的分析 4
三、 模型假设 5
四、 符号说明 5
五、 问题一模型的建立与求解 5
5.1 数据的分析与处理 5
5.1.1 异常数据的处理 5
5.1.2 缺失数据的处理 5
5.1.3 数据标准化 7
5.1.4 正态性检验 8
5.2 相关因素分析 8
5.2.1 斯皮尔曼相关系数 8
5.2.2 显著性检验 9
六、 问题二模型的建立与求解 10
6.1 基于 ARIMA 模型的 PM2.5 浓度预测 10
6.1.1 平稳性检验 10
6.1.2 模型识别与定阶 11
6.1.3 残差检验 11
6.1.4 模型预测结果 12
6.2 基于 LSTM 模型的 PM2.5 浓度预测 13
6.2.1 策略分析 13
6.2.2 模型建立 14
6.2.3 效果评估 15
6.2.4 PM2.5 浓度预测结果 15
七、 问题三模型的建立与求解 16
7.1 AQI 重要相关指标的选取 16
7.2 基于 ARIMA 模型的 AQI 预测 17
7.3 基于 LSTM 模型的 AQI 预测 17
7.3.1 模型建立 17
7.3.2 AQI 值预测结果 18
八、 模型的分析与检验 19
九、 模型的评价、改进与推广 20
9.1 模型的优点 20
9.2 模型的缺点 20
9.3 模型的改进与推广 21
十、 参考文献 21

一、 问题重述

1.1 问题背景

随着改革开放的不断推进，社会经济水平与工业化水平得到快速发展，与此同时空气污染问题也日益严重。空气污染会对人体健康、生态环境、社会发展等多方面产生危害，其污染水平受如 PM2.5、PM10、CO、气温、风速、降水量等诸多因素的综合影响。故进行对 PM2.5 浓度和 AQI 指数等指标的探究与估测，可对未来空气污染情况进行有效预测，进而可做出相关评价和预警，其可帮助相关部门更加有效地对未来空气污染情况进行把控和预防，在污染影响因素的解析以及有效控制策略的制定等方面都有着深远影响，是一项具有重要意义的工作。

1.2 待解决的问题

本文具体要解决的问题如下：

问题一：对所给数据进行分析与处理，筛选出 PM2.5 浓度变化的相关因素，并说明其对 PM2.5 浓度的影响程度。

问题二：划分训练集与测试集，根据所给数据，基于问题一构建出 PM2.5 浓度的多步预测模型，使用均方根误差（RMSE）分别对 3 步、5 步、7 步、12 步预测效果进行评估，并对测试集及其预测结果进行可视化处理。同时使用该预测模型对给定时间的 PM2.5 浓度进行预测。

问题三：构建 AQI 多步预测模型，利用均方根误差（RMSE）对其建模效果进行评估，并对测试集及其预测结果进行可视化处理。同时使用该预测模型对给定时间的 AQI 进行预测，并给出每天空气质量相对应的预警等级。

二、 问题分析

2.1 问题一的分析

针对附件中所给数据，发现其中部分指标所对应数据存在缺失值与异常值，结合各表所给数据的数据特点，考虑对附件 1 中缺失机制为 MAR 且出现连续缺失现象的空缺值采用多重插补法进行填充，故利用其对附件 1 中缺失值与部分指标中出现的异常值 0 值进行插补处理。而针对附件 2 中出现的样本较少的异常值，进行剔除处理后选用计算量较小的拉格朗日差值法进行填充补全。进而再对插补后数据进行标准化处理，并采用正态性检验。根据检验出的各空气质量检测指标结果，结合 Q-Q 图对其统计描述，判断出大部分所给数据不服从正态分布，与皮尔逊相关系数适用范围相违，故选用斯皮尔曼相关系数对其进行相关性分析和显著性检验。根据所得结果，筛选出与 PM2.5 浓度变化相关的因素，并分析其对 PM2.5 浓度变化的影响程度。其分析流程图如图 2-1 所示。

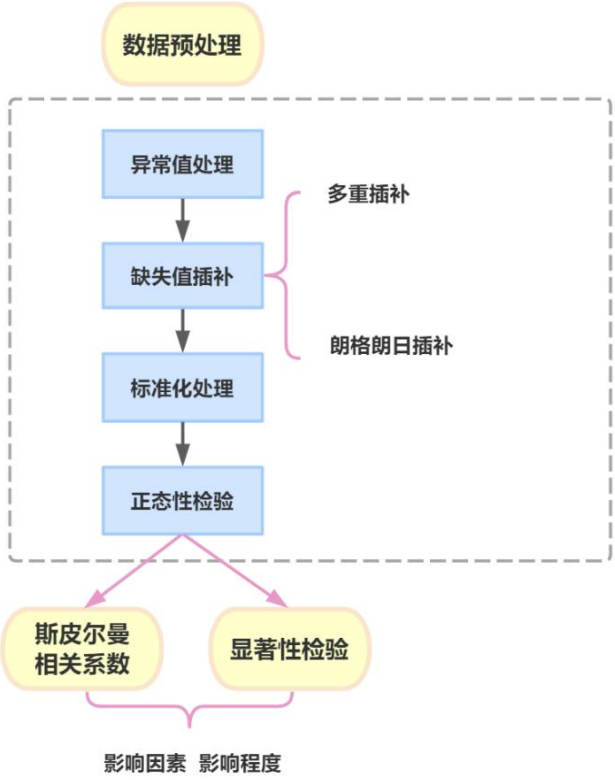

图 2-1 问题一分析流程图

2.2 问题二的分析

为更好预测 PM2.5 的浓度，同时采用 ARIMA 模型与 LSTM 模型对其进行预测，并将预测结果相对比后得出最优预测模型。针对 ARIMA 模型，首先对 PM2.5 浓度序列进行平稳性检验，并通过差分处理将其转化为可使用与 ARIMA 模型的平稳序列。再对该序列进行残差白噪声检验分析，使数据满足模型拟合要求。最后对通过检测的数据选择合适的 ARIMA 模型进行拟合处理，并得出相关预测结果。基于 LSTM 神经网络模型对时间序列较好的预测效果，选择输入影响因子、输出变量、神经元数量，设置合理的超参数等来建立 LSTM 多步预测模型。通过改变预测步长来得到 3、5、7 与 12 步预测模型的均方根误差（RMSE），并以已建立好的神经网络模型与已知的历史数据来预测未来 12 天的 PM2.5 浓度大小。

2.3 问题三的分析

考虑到问题二所建立的 LSTM 多步预测模型对数据的预测效果较好，用该模型来预测未来 12 天 AQI 的数据。首先利用 Spearman 相关系数分析得到影响 AQI 大小的五个相对重要指标，并与 AQI 的计算方式相结合，建立多输入、单输出的 LSTM 多步预测模型，通过计算模型的均方根误差（RMSE）来评估建模效果。同样，通过建立 ARIMA 预测模型来进行对比。综合考虑后得出未来 12 天 AQI 的数据大小、每天空气质量的预警等级以及预警等级颜色的汇总。

三、 模型假设

1. 假设空气污染仅与所给检测指标相关，不考虑其他因素影响。
2. 假设所给数据除缺失值和异常值外均真实可靠且具有强代表性。
3. 假设缺失值和异常值处理后的数据是平滑的，可满足后续模型计算需求。

四、 符号说明

符号	说明
x_j	第j个取值点的横坐标
y_j	第j个取值点的纵坐标
x_i	排序后所得集合x中的第i个元素
y_i	排序后所得集合y中的第i个元素
d_i	排行差分集合中的第i个元素
x_k	第k个观测值
z_k	第k个观测值标准化后所得结果
r_s	Spearman 相关系数
N	所选各组数据中数据个数
p	时序数据本身滞后数
q	预测误差滞后数
d	对原始数据差分处理的阶数
L	滞后算子

五、 问题一模型的建立与求解

5.1 数据的分析与处理

5.1.1 异常数据的处理

对所给数据进行筛选分析发现，附件 1 中 AQI 为 0 的数据所对应的空气质量等级为无，PM10、SO_2 与 PM2.5 指数均出现 0 值，且 2015 年 1 月 27 日的 SO_2 对应浓度为 1 μg/m^3，其均与实际情况不符，故对该部分数据进行剔除和插补处理。附件 2 中平均气压、平均风速、平均气温等指标下所给数据均出现了 999990 等异常值现象，对该部分先进行删除处理，后续再利用拉格朗日插值法进行数据填充。

5.1.2 缺失数据的处理

1. 针对附件 1 数据

考虑到附件 1 中空缺数据的缺失机制为随机缺失（MAR），即缺失发生的概率仅

依赖于已观测变量而与未观测到的变量无关[1]，且部分数据在连续时间范围内出现了多项指标测量值的缺失，故利用 SPSS 软件对其缺失数据进行多重插补，所得结果如表 5-1 所示，其中红色字体为插补值。

表 5-1 附件 1 缺失数据部分插补结果

年	月	日	AQI	质量等级	PM10	O3	SO2	PM2.5	NO2	CO
2015	1	26	172	中度污染	32.5	36	36	168	86	1.7
2015	1	27	140	轻度污染	8	42	28	107	53	1.2
2015	1	28	202	重度污染	5	89	46	32	116	2
2015	1	29	182	中度污染	25	62	34	64	75	1.5
2015	1	30	101	轻度污染	58	70	25	83	67	1
2015	1	31	190	中度污染	89	57	33	132	90	1.6
2017	12	1	64	良	61	38	6	53	40	0.7
2017	12	2	78	良	88	19	9	69	58	0.7
2017	12	3	114	轻度污染	107	56	11	84	70	1.5
2017	12	4	200	中度污染	164	18	10	180	56	1.4
2017	12	5	270	重度污染	147	95	14	162	68	1.9
2017	12	6	134	轻度污染	161	53	24	137	88	1.4
2017	12	7	180	中度污染	120	115	18	100	72	1.7
2017	12	8	109	轻度污染	108	60	16	86	55	1.2
2017	12	9	106	轻度污染	123	45	15	70	75	1.4
2017	12	10	129	轻度污染	148	78	17	75	76	1.9
2017	12	11	111	轻度污染	116	74	19	53	76	1.5
2017	12	12	83	良	105	40	19	67	65	1

2. 针对附件 2 数据

考虑到 5.1.1 中所剔除的异常值样本数较少，且未出现大面积的连续时间缺失现象，故对其采用计算量较小的拉格朗日插补法对其进行填充处理。根据缺失值的前后 5 个共 10 个值，利用 Lagrange 插值法进行数据填充，原理如下：

根据已知的$n+1$个取值点$(x_0,y_0),(x_1,y_1),\cdots,(x_n,y_n)$，构建每个取值点所对应的拉格朗日基本多项式$L_j(x)$，其表达式如下:

$$L_j(x)=\frac{(x-x_0)\cdots(x-x_{j-1})(x-x_{j+1})\cdots(x-x_n)}{(x_j-x_0)\cdots(x_j-x_{j-1})(x_j-x_{j+1})\cdots(x_j-x_n)} \tag{1}$$

进而构建出拉格朗日插值多项式$L(x)$，其表达式为：

$$L(x)=\sum_{j=1}^{n} y_j L_j(x) \tag{2}$$

最后利用上述多项式对缺失值进行插补，部分插补结果如 5-2 所示。

表 5-2 附件 2 缺失数据部分插补结果

区站号	年	月	日	降水量	平均气压	平均 2 分钟风速	平均气温	平均相对湿度
1	2016	1	20	0.0	1026.5	0.1	3.5	60.2
1	2016	2	25	0.0	1031.5	0.8	9.3	65.1
1	2016	3	22	0.0	1020.8	2.4	12.5	67.9
1	2016	3	23	0.8	1025.9	3.9	12.9	59.5
1	2016	4	15	0.1	1004.4	4.3	21.5	74.0

并以 2016 年 4 月 15 日的数据和 2016 年 1 月 20 日平均相对湿度为例，利用 Lagrange 插值法对缺失数据进行插补后作出相应的拟合曲线，结果分别如图 5-1 和图 5-2 所示，由图可看出插值后的数据与原数据可构成较好的拟合曲线。

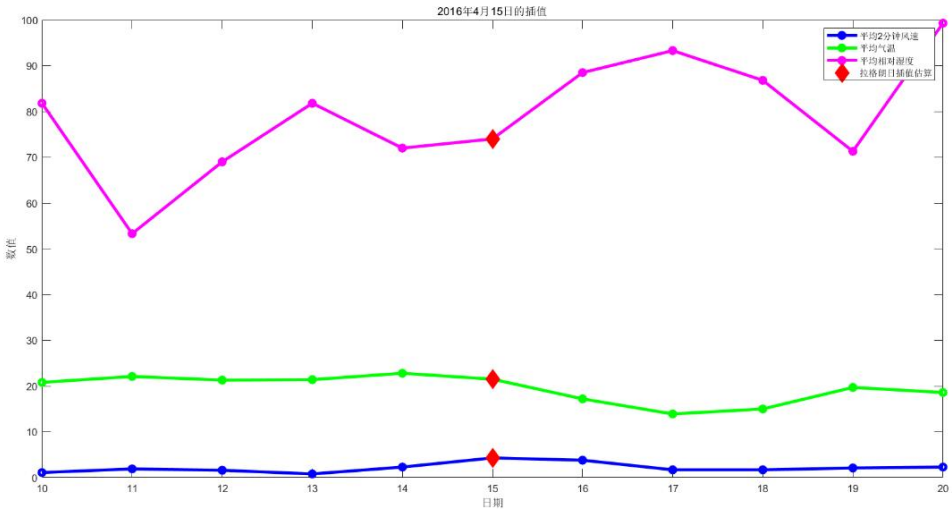

图 5-1 2016 年 4 月 15 日数据插值后的拟合曲线

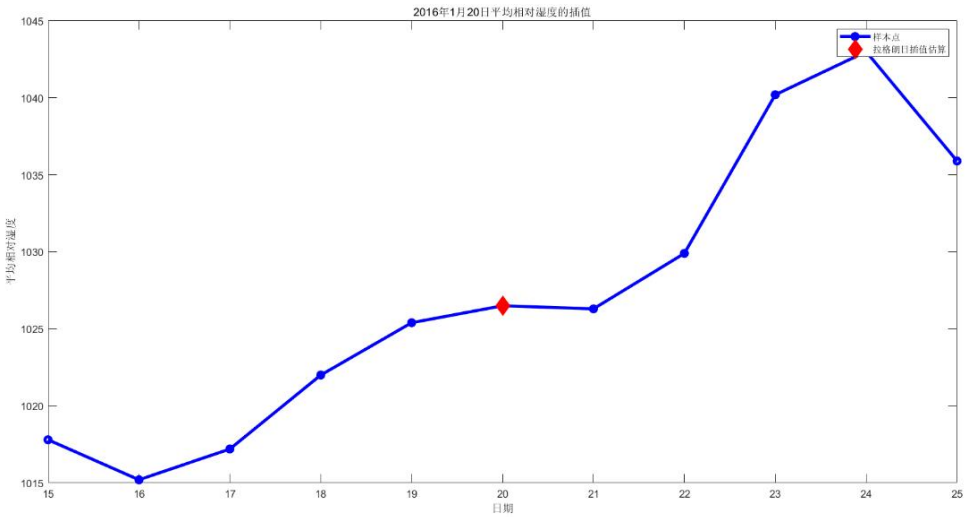

图 5-2 2016 年 1 月 20 日平均相对湿度插值后的拟合曲线

附件 1 与附件 2 的完整插补后数据见支撑材料。

5.1.3 数据标准化

针对所给数据，以“污染物浓度数据”为例，其中 PM10、PM2.5 等多个检测指标中的数值均出现了三位数，而 CO 浓度维持在 3 以下。若数据量纲差距较大，带入模型后可能会导致分析时的重心偏移，即易忽略较小数据的变化影响，从而降低最终预测结果的精准程度。

设x_k为第k个观测值，μ为均值，σ为标准差，定义标准化为：

$$z_k = \frac{x_k - \mu}{\sigma} \tag{1}$$

标准化后的完整数据见附录 5。

5.1.4 正态性检验

对标准化后的完整插补数据进行 Kolmogorov-Smirnov 检验(KS 检验)和 Shapiro-Wilk 检验(SW 检验)，并利用 Q-Q 图以 SO_2 浓度为例对其进行统计描述，所得结果分别见表 5-3 和图 5-3。

表 5-3 正态性检验结果

	Kolmogorov-Smirnov(K)[a]			Shapiro-Wilk		
	统计	df	显著性	统计	df	显著性
AQI	.080	3041	.000	.887	3041	.000
PM10	.085	3041	.000	.928	3041	.000
O3	.052	3041	.000	.978	3041	.000
SO2	.185	3041	.000	.760	3041	.000
PM2.5	.133	3041	.000	.846	3041	.000
NO2	.087	3041	.000	.950	3041	.000
CO	.143	3041	.000	.927	3041	.000
降水量	.389	3041	.000	.292	3041	.000
平均气压	.222	3041	.000	.398	3041	.000
平均 2 分钟风速	.121	3041	.000	.696	3041	.000
平均气温	.064	3041	.000	.944	3041	.000
平均相对湿度	.044	3041	.000	.982	3041	.000

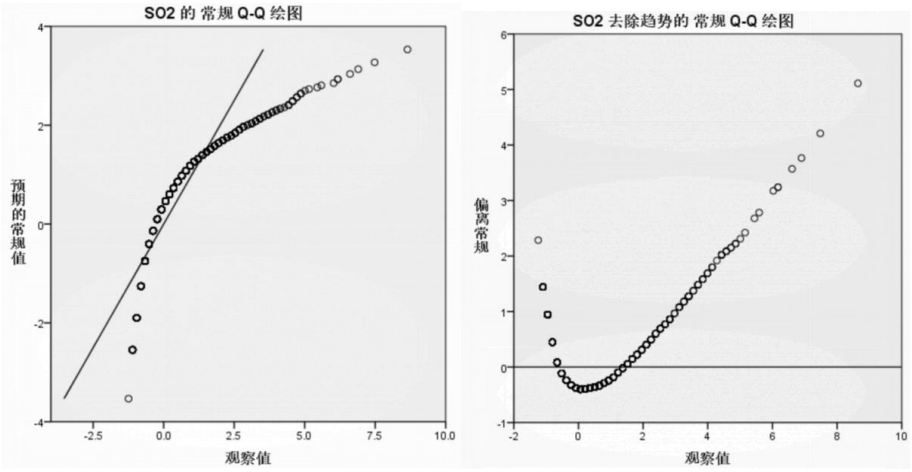

(a) (b)

图 5-3 SO_2 浓度的 Q-Q 图

由表可知，其中显著性水平 p 均小于 0.05，且结合 Q-Q 图可知，数值点分布与直线趋势呈现较大偏离状态，基于此可认为数据不满足正态性，故不能利用皮尔逊相关系数衡量各指标间的关系。

5.2 相关因素分析

5.2.1 斯皮尔曼相关系数

斯皮尔曼相关系数可衡量两组变量之间的相关性，且相比于皮尔逊相关系数，斯皮尔曼相关系数不要求数据呈现正态分布[2]，更适用于所给的非正态性数据。其具体原理如下：

取两组个数均为 N 的独立同分布数据 X、Y,两组变量中第 $i(1 \leqslant i \leqslant N)$ 个值分别为 X_i、Y_i，并对其进行排序处理得到两个元素排行集合 x、y，其中的元素 x_i、y_i 分别

表示X_i和Y_i分别在X、Y中所对应的排行。d为集合x、y中对应元素插值所组成的排行差分集合，其中$d_i = x_i - y_i$，$(1 \leqslant i \leqslant N)$。Spearman 相关系数$r_s$可由排行差分集合$d$计算得出，其表达式如下：

$$r_s = 1 - \frac{6\sum_{i=1}^{N} d_i^2}{N(N^2-1)} \tag{1}$$

斯皮尔曼相关系数的取范围值为$[-1,1]$，$r_s > 0$说明两组变量间呈现正相关，$r_s < 0$说明呈现负相关，且$|r_s|$越大，表面变量间所存在的相关性越强。

利用 MATLAB 对标准化处理后数据进行 Spearman 相关性分析，所得结果以热图形式表示，见图 5-4。

图 5-4 各指标间 Spearman 相关系数热图

由图中数据可得，与 PM2.5 相关程度较为显著的分别为平均气温、SO_2、NO_2、CO 与 PM10，其与 PM2.5 间的相关系数分别为-0.5384、0.5868、0.7109、0.7131 和 0.8746。其中 PM10 相关系数值介于 0.8 和 1.0 之间，表明其与 PM2.5 呈现极强相关；NO_2、CO 相关系数值介于 0.6 和 0.8 之间，表明其与 PM2.5 呈现强相关；SO_2、平均气温相关系数值介于 0.4 和 0.6 之间，表明其与 PM2.5 呈现中等程度相关。

5.2.2 显著性检验

由上述计算得出 Spearman 相关系数r_s，但该值易受到样本数量、样本随机性等的影响，故为考察样本相关系数的可靠程度，需对其进行显著性检验。

首先假定原假设H_0：样本不相关，其后选取进行计算检验的统计量，以下选用t分布检验，其表达式如下：

$$t = |r_s|\sqrt{\frac{n-2}{1-{r_s}^2}} \sim t(n-2) \tag{1}$$

进而根据选定的显著性水平s和自由度$d_f = n-2$，结合t分布表查找出

$t_{s/2}(n-2)$的临界值。若$|t|>t_{s/2}$，则可拒绝原假设H_0，即两组变量间存在显著的线性关系。利用 SPSS 软件对上述数据与 PM2.5 间的相关系数进行显著性检验所得结果如表 5-4 所示。

表 5-4 PM2.5 显著性检验结果

	相关系数	显著性（双尾）	N
AQI	.741**	0	3041
PM10	.875**	0	3041
O3	-.207**	0	3041
SO2	.587**	0	3041
PM2.5	1	.	3041
NO2	.711**	0	3041
CO	.713**	0	3041
降水量	-.232**	0	3041
平均气压	.509**	0	3041
平均 2 分钟风速	-.294**	0	3041
平均气温	-.538**	0	3041
平均相对湿度	-.036*	0.047	3041

**. 相关性在 0.01 级别显著（双尾）

*. 相关性在 0.05 级别显著（双尾）

由表中数据及表下注释可分析得到，5.2.1 中所筛选出的四个变量 SO_2、NO_2、CO 和 PM10 均与 PM2.5 呈现正相关，且相关性级别显著，平均气温与其呈现负相关且相关性较为显著，故可验证得所筛选出的该五项指标为 PM2.5 浓度变化的影响因素，且影响程度剧烈。

六、 问题二模型的建立与求解

6.1 基于 ARIMA 模型的 PM2.5 浓度预测

ARIMA 模型又称为自回归移动模型[3]，是一种时间序列建模方法。其大致思路为：将预测的目标随时间推移所产生的时间序列视作一串随机序列，用相应的数学模型对该序列进行近似描述，模型确立后利用时间序列的过去值与现在值对未来值进行预测估计。其模型表达式如下：

$$\left(1-\sum_{i=1}^{p}\Phi_i L^i\right)(1-L)^d X_i=\left(1+\sum_{i=1}^{q}\theta_i L^i\right)\varepsilon_i \tag{1}$$

其中p,d,q为模型中的三个参数，p代表时序数据本身的滞后数，d为原始序列转化为平稳序列所需要进行差分处理的阶数，q代表预测误差的滞后数。L为滞后算子，ε_i为白噪声序列，且$d\in Z, d>0$。

6.1.1 平稳性检验

ARIMA 模型中已假定时间序列与过去值和外部干扰间存在一定因果关系，而该因果关系在时间序列上是连续的，必须要求序列为平稳的随机序列，才能利用时间序列进行参数估计[4]。序列平稳性的检测方法有图检验法和单位根检验法（ADF），其中图检验法包含时序图和相关图两种。利用 MATLAB 针对上述数据绘制出的时序图如图 6-1 所示。

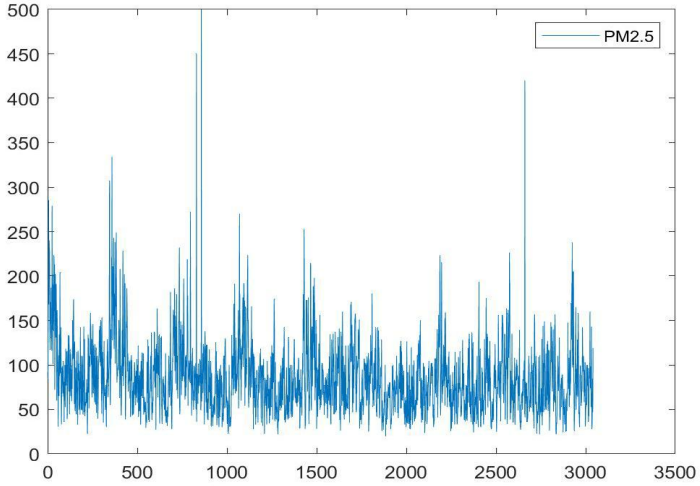

图 6-1 PM2.5 浓度时序数据图

由上图可分析得出，PM2.5 浓度序列具有一定的趋势，但大部分数据未始终在一个常数值附近波动，可初步判定该序列未通过平稳性检验，不为平稳时间序列。故为消除时间序列的特征信息及季节性因素，对该序列进行一阶差分处理，直至原始序列趋于平稳，其一般形式为：

$$\Delta y_t = y_t - y_{t-1} \tag{1}$$

其中y_t为当前时刻时间序列，y_{t-1}为上一时刻时间序列。该序列进行一阶差分处理后一定程度上消除了季节性因素和趋势性特征，此时表现平稳，故$d=1$。

6.1.2 模型识别与定阶

确定为平稳序列后，通过图 6-2 自相关（ACF）和图 6-3 偏自相关（PAC）及其相关系数可以得出，其 p、q 值分别为 2 和 1，故最终选择 ARIMA（2,1,1）作为模型。

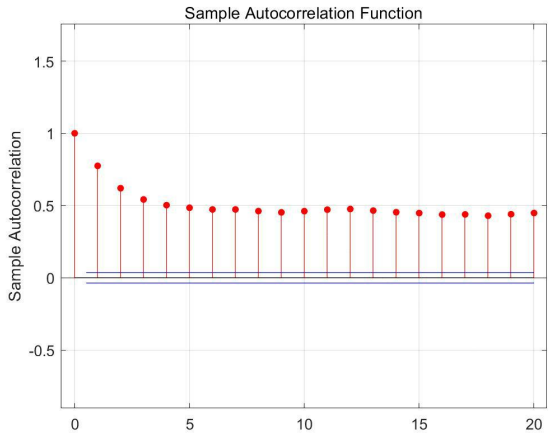

图 6-2 PM2.5 自相关图

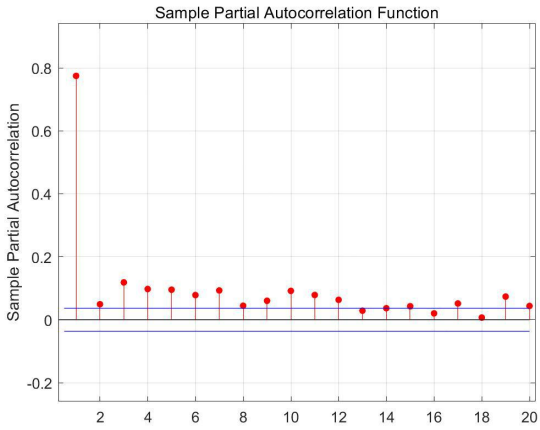

图 6-3 PM2.5 偏自相关图

6.1.3 残差检验

模型建立后，需对残差的分布情况进行白噪声检验，其结果见图 6-4。以第一张图为例，可看出残差序列基本围绕着均值进行上下波动，故可初步判断该模型的残差序列具有一定的平稳性。结合其余图可综合分析得到，该模型的残差分布较为正常，时序图的变化相对平稳，说明其拟合度较好，满足白噪声序列原始序列中的有效信息已经得到了较为充分的获取，故该模型可用于预测。

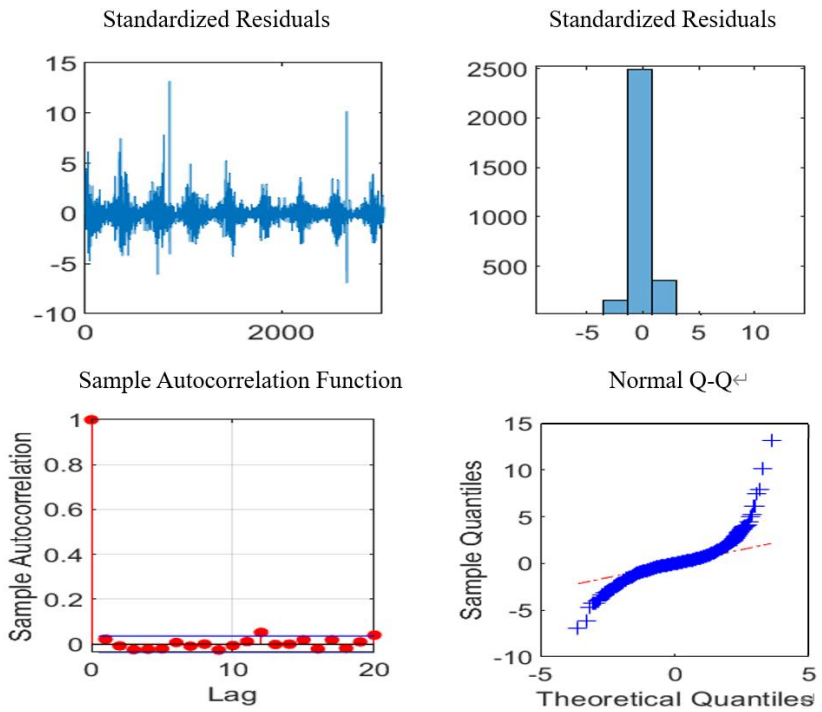

图 6-4 PM2.5 模型诊断结果

6.1.4 模型预测结果

基于上述模型对所给时间段，以 2015 年 1 月 1 日至 2021 年 7 月 27 日的数据为训练集（2400 份，约占数据的 80%），以 2021 年 7 月 28 日至 2023 年 4 月 29 日的数据为测试集（641 份，约占数据的 20%），基于此运用 MATLAB 通过训练得出的 ARIMA 模型对 PM2.5 浓度进行预测，其预测结果如表 6-1 和图 6-5 所示。

表 6-1 PM2.5 浓度预测结果表

日期（年/月/日）	2023/4/30	2023/5/1	2023/5/2	2023/5/3	2023/5/4	2023/5/5	2023/5/6	2023/5/7	2023/5/8	2023/5/9	2023/5/10	2023/5/11
PM2.5	40.18	36.74	33.34	34.38	34.27	33.60	33.80	33.60	33.54	33.48	33.59	33.37

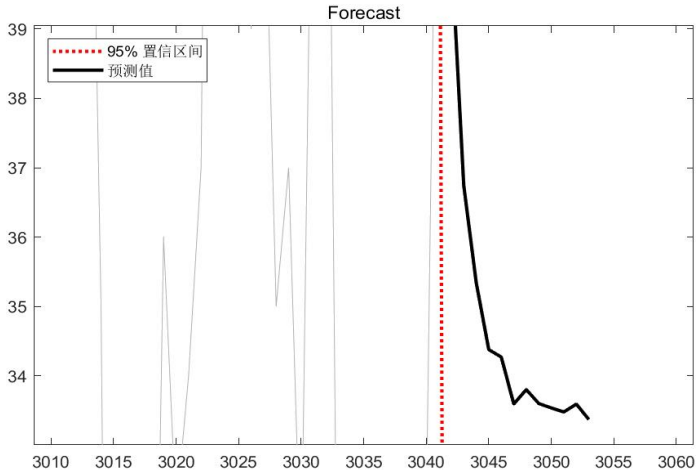

图 6-5 PM2.5 浓度预测结果图

结合图像和相关计算可得，在上述训练生成的 ARIMA 模型中，模型拟合度一般，预测结果误差较大，其预测效果不理想。分析其原因，可能是数据分布不具有较强的时间序列性，故其预测结果不为 PM2.5 浓度的较优预测值。

6.2 基于 LSTM 模型的 PM2.5 浓度预测

6.2.1 策略分析

LSTM 神经网络是循环神经网络(RNN)的扩展[5]，其在传统 RNN 的基础上增加了相关记忆单元，一个 LSTM 单元由遗忘门、输入门和输出门三个模块共同构成，且该三个部分用于控制内部信息的流入与流出，实现记忆或遗忘的功能，其单元基本结构如图 6-6 所示：

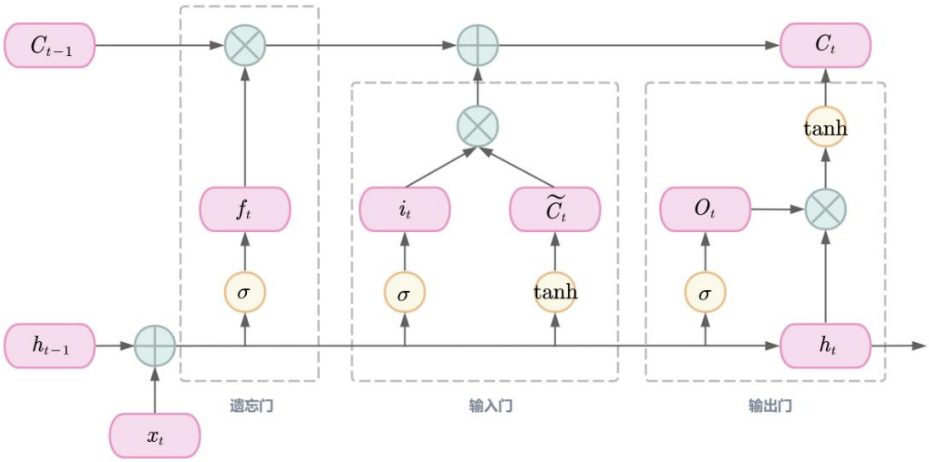

图 6-6 LSTM 单元基本结构图

其中，**遗忘门**用于评估之前时刻细胞状态中的记忆信息对于当前时刻的重要性，将当前时刻与上一时刻的输出作为 Sigmoid 函数的输入，用以控制上一单元状态被遗忘的程度。**输入门**和 tanh 函数相辅构成，用以控制新输入信息的量。**输出门**可决定所输出的信息，主要使用 tanh 函数对当前细胞状态进行处理，进而结合 Sigmoid 函数所得权值来对部分细胞状态信息进行过滤，得到下一时刻的输出。主要公式如下：

$$\begin{cases} f_t = \sigma(W_f[h_{t-1}, X_t] + b_f) \\ i_t = \sigma(W_t[h_{t-1}, X_t] + b_i) \\ \widetilde{C}_t = \tanh(W_c[h_{t-1}, X_t] + b_c) \\ O_t = \sigma(W_o[h_{t-1}, X_t] + b_o) \\ C_t = f_t * C_{t-1} + i_t * \widetilde{C}_t \\ h_t = O_t * \tanh C_t \end{cases} \tag{1}$$

上述公式中，f_t、i_t、O_t分别为遗忘门、输入门和输出门的输出；$\widetilde{C}_t$为当前输入记忆；C_{t-1}为上一时刻细胞状态；C_t为当前时刻细胞状态；h_{t-1}为当前时刻的输出；W_f、W_i、W_o、W_c分别为遗忘门、输入门、输出门和输出门中间变量与当前时刻输入X_t和上一时刻输出h_{t-1}乘法运算后的所得权重；b_f、b_i、b_o、b_c为偏置向量；σ代表 Sigmoid 函数;tanh 为双曲正切函数。

6.2.2 模型建立

由上述 LSTM 模型原理可以看出，可将对多个时间序列数据输入该模型，进而得出未来的预测值。故对于所给污染物浓度数据，同样以 2015 年 1 月 1 日至 2021 年 7 月 27 日的数据为训练集（2400 份，约占数据的 80%），以 2021 年 7 月 28 日至 2023 年 4 月 29 日的数据为测试集（641 份，约占数据的 20%），将其标准化处理后导入 Python 中，通过 LSTM 神经网络算法对 PM2.5 浓度进行预测。将得到的实际值和预测值间的差异进行验证，设置步长为 1，所得测试结果及其可视化如图 6-7 所示。从图中可分析得到，PM2.5 的实际值趋势与预测值趋势基本吻合，但也存在一定的差异，其 RMSE 值为 18.8832。

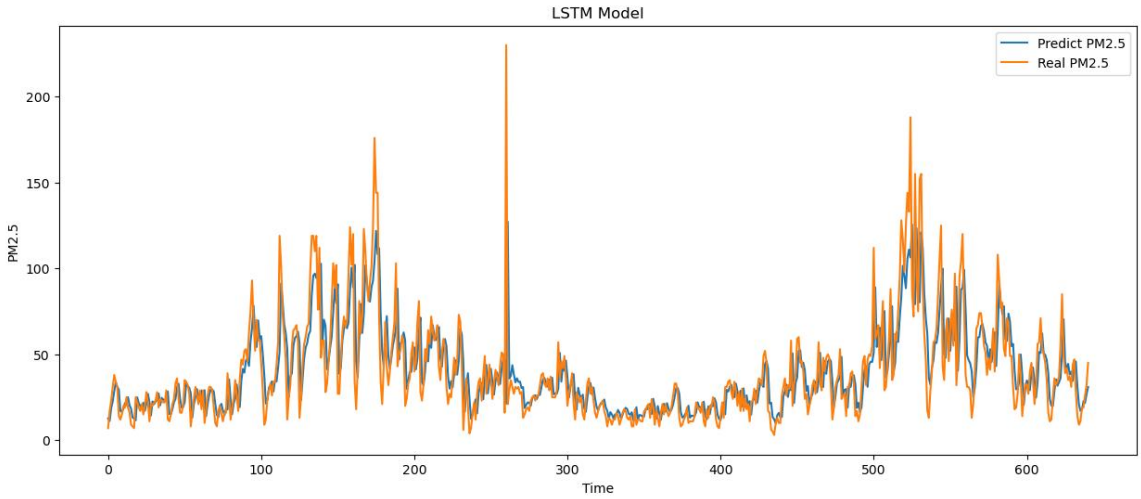

图 6-7 PM2.5 浓度实际值和预测值验证图（1 步预测步长）

预测步长（prediction horizon）用于在时间序列预测的问题中，对未来数据的时间跨度进行预测，一般以时间步长（time steps）为单位表示。时间序列预测问题中，其长度是问题本身决定。且其长度对模型的训练和评估具有一定影响，预测步长越长，模型所需处理的数据越多，模型复杂度也会因此加大，导致预测精度降低。结合所给数据，选用不同步长得出 3 步、5 步、7 步和 12 步的测试集预测结果及其可视化图表。其中步长为 3 的预测图如图 6-8 所示。

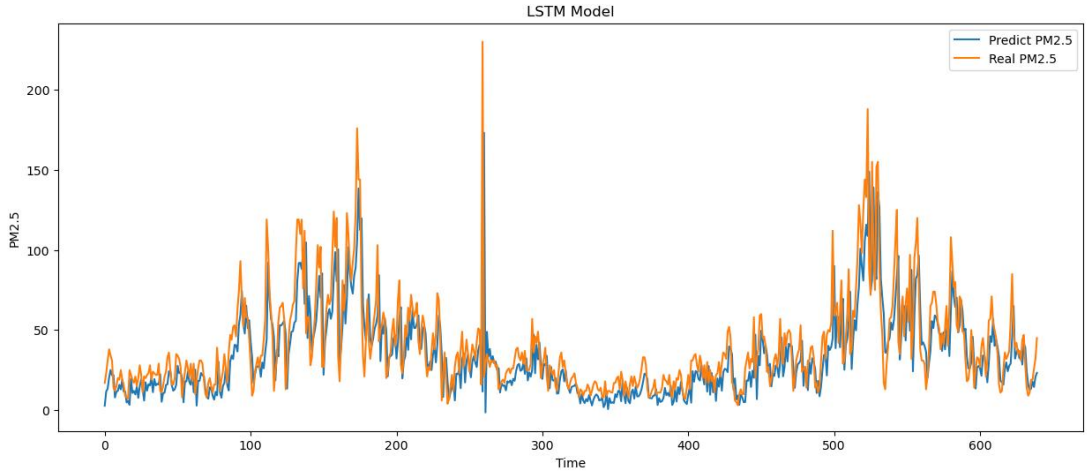

图 6-8 PM2.5 浓度预测图（3 步预测步长）

6.2.3 效果评估

为对预测结果进行量化比较，验证上述模型的有效性，可采用均方根误差（RMSE）对模型性能进行评价[6]。RMSE 可反映预测值与实际值的平均绝对偏离程度，其数学公式描述如下：

$$RMSE=\sqrt{\frac{1}{N}\sum_{t=1}^{N}\left[\hat{y}(t)-y(t)\right]^2} \tag{1}$$

其中，N 为测试的样本个数，$\hat{y}(t)$ 为 t 时刻的预测值，$y(t)$ 为 t 时刻的真实值。

利用 RMSE 对 3 步、5 步、7 步和 12 步预测效果进行评估所得结果如表 6-2 所示，其值越大说明该模型预测结果出现较多偏差，表示模型稳定性较弱，反之稳定性较强，出现偏差情况较少。

表 6-2 PM2.5 浓度预测的 RMSE 结果

预测步长	3 步预测	5 步预测	7 步预测	12 步预测
RMSE	19.4574	21.6210	21.4685	22.0202

结合表中所得结果，其值均在可接受范围内，表明该模型的整体预测结果偏差较小，且稳定性较强，有较好的拟合效果。且随着预测步长的增加，RMSE 值有累积的趋势。

6.2.4 PM2.5 浓度预测结果

基于上述建立出的 LSTM 模型，运用 Python 设置 n_steps 值为 60,也即利用目标预测时间前 60 天已有历史数据，对附件 3 中所给定的时间段的 PM2.5 浓度进行预测，其结果如表 6-3 和图 6-9 所示。

表 6-3 PM2.5 浓度预测结果

日期（年/月/日）	2023/4/30	2023/5/1	2023/5/2	2023/5/3	2023/5/4	2023/5/5	2023/5/6	2023/5/7	2023/5/8	2023/5/9	2023/5/10	2023/5/11
PM2.5	34.47	33.02	42.54	28.71	25.64	19.03	27.43	30.02	26.42	18.09	25.66	40.41

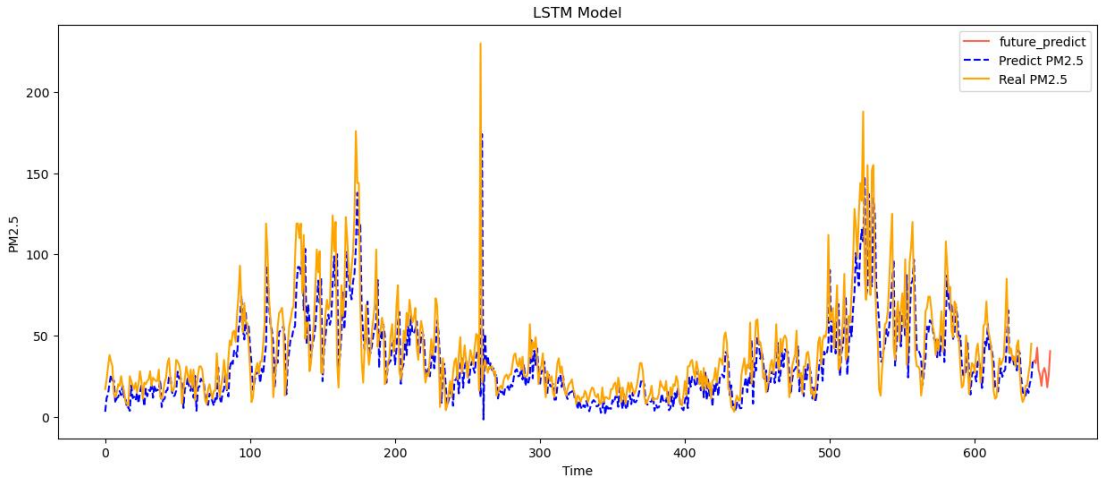

图 6-9 未来 12 天 PM2.5 浓度预测结果可视化

七、 问题三模型的建立与求解

7.1 AQI 重要相关指标的选取

AQI 又称空气质量指数，是一种用于评价空气质量的量化指标。其计算过程中，选用 PM2.5、PM10、SO_2、NO_2 等污染物中最高的空气质量分指数（IAQI）作为当前的空气质量指数，代表当前空气质量状态，其计算公式如下：

$$AQI = \max\{IAQI_1, IAQI_2, \cdots, IAQI_n\} \tag{1}$$

其中 $IAQI_n$ 代表评价指标 n 所对于的空气质量分指数。

进而，通过 Spearman 相关系数计算分析得到各项检测指标与 AQI 指数间的相关性关系，其结果见表 7-1。

表 7-1 AQI 与各项指标间相关系数表

	相关系数	显著性（双尾）	N
AQI	1	.	3041
PM10	.782**	0	3041
O3	.239**	0	3041
SO2	.570**	0	3041
PM2.5	.741**	0	3041
NO2	.612**	0	3041
CO	.580**	0	3041
降水量	-.426**	0	3041
平均气压	.193**	0	3041
平均 2 分钟风速	-.347**	0	3041
平均气温	-.144**	0	3041
平均相对湿度	-.291**	0	3041

**. 相关性在 0.01 级别显著（双尾）

*. 相关性在 0.05 级别显著（双尾）

表中结果表明，与 AQI 指数呈现较强相关性的指标分别为 PM2.5、PM10、SO_2、NO_2 和 CO。AQI 指数与该五种污染物自 2015 年 1 月 1 日至 2023 年 4 月 29 日的原始数据走势情况[7]如图 7-1 所示。

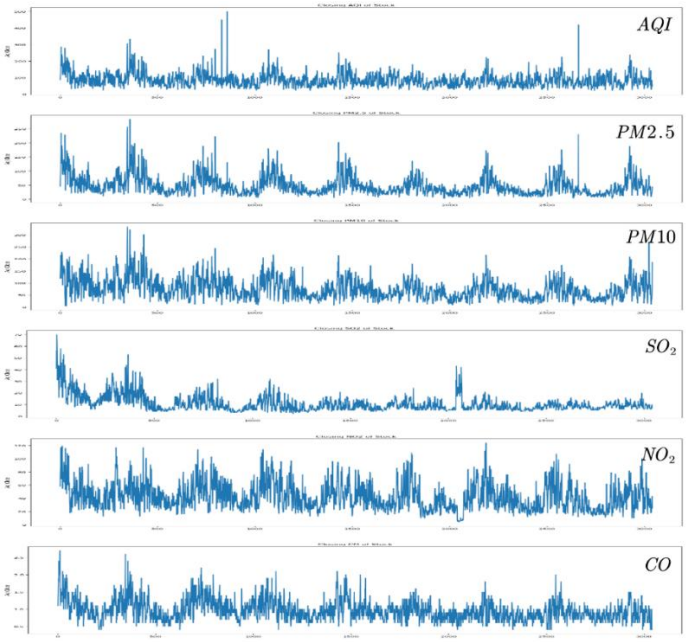

图 7-1 各指标原始数据走势

7.2 基于 ARIMA 模型的 AQI 预测

与 6.1 原理相似，首先对 AQI 序列进行平稳性分析，其未通过平稳性检验，进而运用差分法将其处理至总体趋于平稳，并确定其模型为 ARIMA（2，1，1）。再对其进行残差检验，分析得出其可用于预测，且预测结果如表 7-2、7-3 和图 7-2 所示。（上述过程具体分析所得图表见附录 1）

表 7-2 AQI 预测结果表

日期（年/月/日）	2023/4/30	2023/5/1	2023/5/2	2023/5/3	2023/5/4	2023/5/5	2023/5/6	2023/5/7	2023/5/8	2023/5/9	2023/5/10	2023/5/11
AQI	97.00	87.72	82.39	77.60	78.42	79.02	76.21	76.94	78.83	76.56	76.25	78.64
空气质量等级	良	良	良	良	良	良	良	良	良	良	良	良
预警等级颜色	无	无	无	无	无	无	无	无	无	无	无	无

表 7-3 预警等级颜色次数汇总

预警等级颜色	蓝色	黄色	橙色	红色	无	汇总
天数（天）	0	0	0	0	12	12

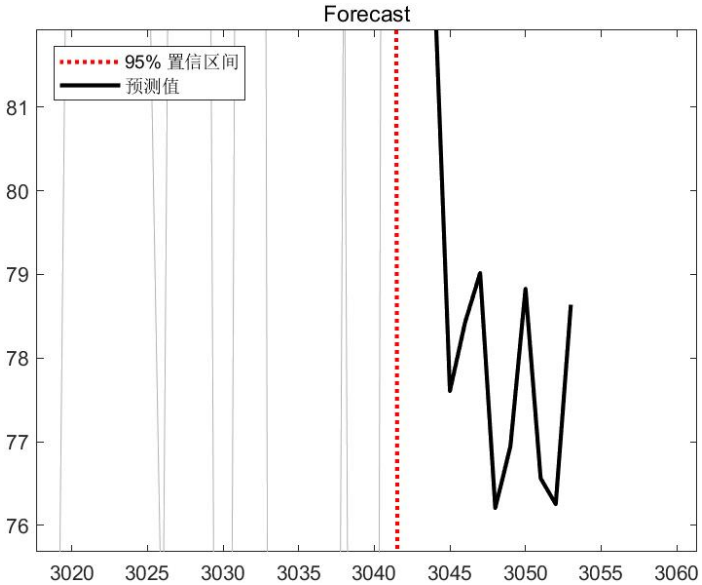

图 7-2 PM2.5 浓度预测结果图

7.3 基于 LSTM 模型的 AQI 预测

7.3.1 模型建立

基于上述选取的五项指标，以及问题 2 中 LSTM 模型各预测步长的 RMAE 值对

比分析，选择误差较小的预测步长值，设置其为 1，并建立 LSTM 神经网络模型对未来 12 天的 AQI 指数进行预测。计算得到 RMSE 值为 31.2989，测试集预测结果及其可视化结果见图 7-3。

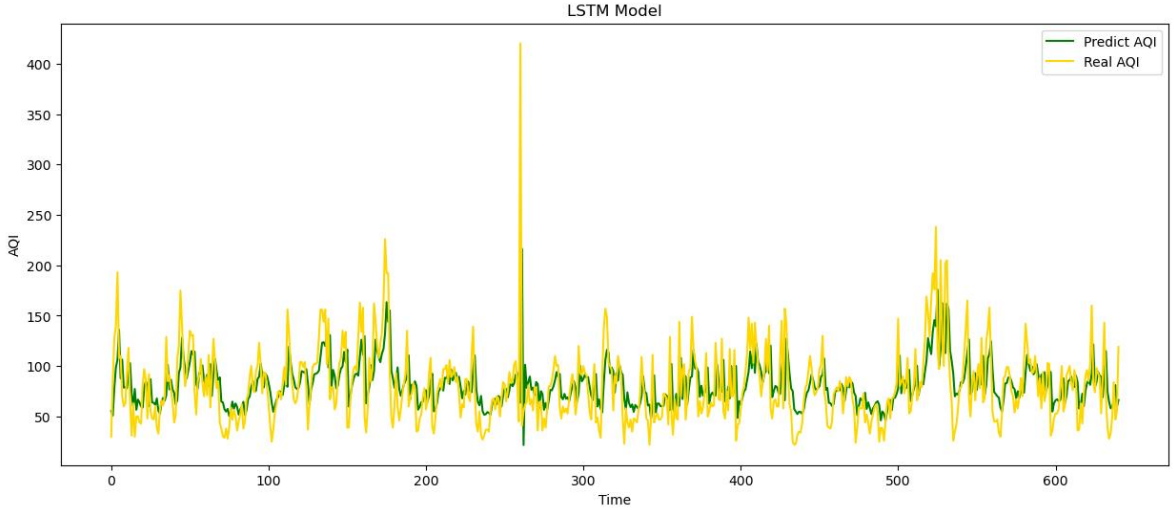

图 7-3 测试集 AQI 预测图

7.3.2 AQI 值预测结果

基于上述建立出的 LSTM 模型，设置预测步长为 1，同 6.2.4 选取目标预测时间前 60 天指标数据对所给时间段的 AQI 值进行预测，并给出其对应的空气质量预警等级及其汇总，其结果分别如表 7-4 和表 7-5 以及图 7-4 所示。

表 7-4 AQI 预测结果

日期（年/月/日）	2023/4/30	2023/5/1	2023/5/2	2023/5/3	2023/5/4	2023/5/5	2023/5/6	2023/5/7	2023/5/8	2023/5/9	2023/5/10	2023/5/11
AQI	78.62	112.20	82.45	68.75	72.21	95.33	62.25	59.63	78.62	101.44	120.69	84.66
空气质量等级	良	轻度污染	良	良	良	良	良	良	良	轻度污染	轻度污染	良
预警等级颜色	无	无	无	无	无	无	无	无	无	无	无	无

表 7-5 预警等级颜色次数汇总

预警等级颜色	蓝色	黄色	橙色	红色	无	汇总
天数（天）	0	0	0	0	12	12

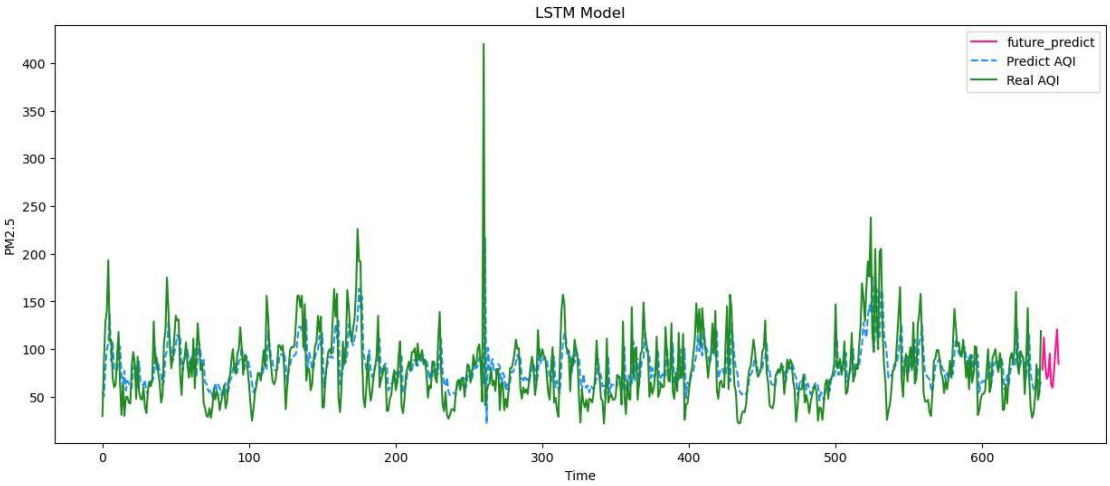

图 7-4 未来 12 天 AQI 预测结果可视化

八、 模型的分析与检验

1. **残差分析（residual analysis）**指，根据残差所提供的信息，对模型假设的合理性及数据的可靠性称进行考察，分析出其可靠性、周期性或其它干扰 ，进而判断模型的假设正确与否。残差指观测值与预测值（拟合值）间的差值，即实际观察值与预测估计值间的差。综合分析 LSTM 模型对 PM2.5 浓度和 AQI 预测的残差图与测试集预测结果图，可知该模型拟合度较好，具有一定的可靠性，PM2.5 浓度与 AQI 测试集残差图见图 8-1。

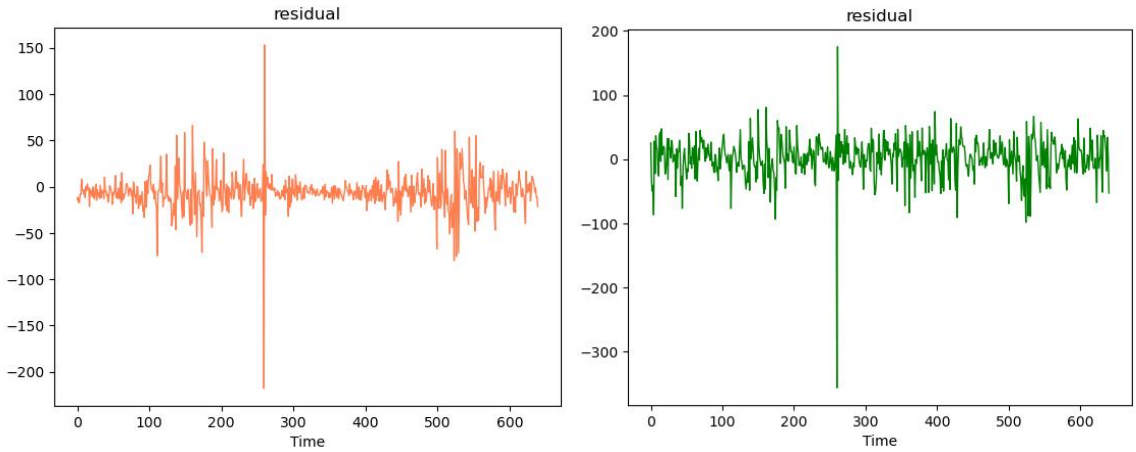

图 8-1 测试集残差图

平均绝对误差（MAE）可反映预测值与实际值间的平均系统性偏离程度，**平均绝对百分比误差（MAPE）**可反映预测值与实际值的偏离相对于实际值的平均偏离程度，**R 方值（R^2-score）**可用于比较不同量纲下模型的优良性，其公式如下（其中变量名称与 6.2.3（9）式中定义相同）：

$$MAE = \frac{1}{N}\sum\left|\hat{y}(t) - y(t)\right| \tag{1}$$

$$MAPE = \frac{1}{N}\sum\left|\frac{\hat{y}(t)-y(t)}{y(t)}\right| \tag{2}$$

$$R^2 = 1-\frac{\sum\left[\hat{y}(t)-y(t)\right]^2}{\sum\left[\bar{y}(t)-y(t)\right]^2} \tag{13}$$

经过计算所得以上两个指标数据，结果见表 8-1。

表 8-1 预测结果误差分析

	MAE	R^2	MAPE
PM2.5	11.89	0.64	0.39
AQI	21.47	0.58	0.33

通过表中数据可分析得出，LSTM 模型的预测结果预测偏差较小，拟合效果较好，且其预测结果的稳定性较强，可满足实际预测需求。

2. 通过对比分析 ARIMA 模型与 LSTM 模型的部分预测值与真实值，得出 LSTM 模型的预测效果较好，其预测对比图见图 8-2。

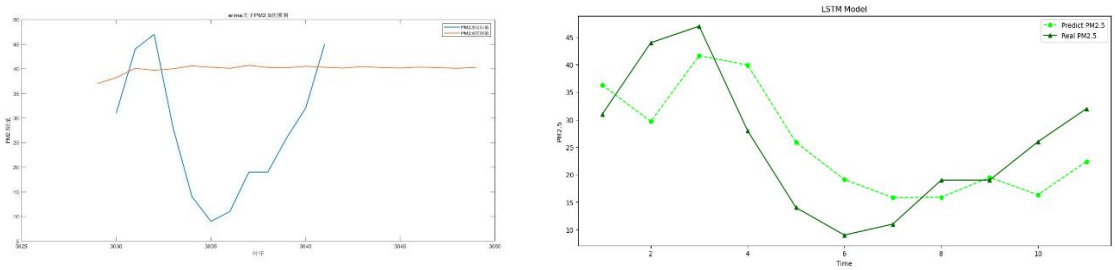

图 8-2 ARIMA 与 LSTM 模型预测对比曲线图

九、 模型的评价、改进与推广

9.1 模型的优点

1. 多重插补稳健性好，其偏差值较小，能较好地保持各变量间的关系，提高了估计的有效性和可靠性。

2. ARIMA 模型较为简单，时序图较为直观，自相关与偏自相关图结果准确。

3. LSTM 模型相比于传统 RNN，可处理量级较大序列，且在长序列建模问题上有一定优势，具有长时记忆的功能，可有效解决训练长序列数据时梯度消失和梯度爆炸问题。

4. LSTM 模型考虑了空气质量指数 AQI 自身随时间变化的影响的同时，也考虑了其它相关影响因素对 AQI 的影响。

9.2 模型的缺点

1. ARIMA 模型要求时序数据本身或者经过差分化后是稳定的，其本质上仅能捕捉线性关系，不能处理非线性关系。

2. LSTM 模型在并行处理上存在劣势，且计算量较大，耗时较长。

9.3 模型的改进与推广

ARIMA 模型对异常值有较好预测效果，LSTM 模型有较好的非线性拟合能力。但 ARIMA 模型没有充分考虑相关因素对预测指标的影响，LSTM 模型对离群点的预测效果不佳。 故可将两种方法融合，首先运用 ARIMA 模型对预测指标时间序列的线性特征进行提取，再将预测值和真实值相减得到残差序列，进而将残差序列和预测指标影响因素作为 LSTM 模型的输入，对预测指标的数据残差进行修正处理，最后将修正后的结果与 ARIMA 模型的预测结果相结合得到更为精确的预测结果。

本文 LSTM 多步预测模型对时间序列数据有较好的预测精度，可移植到对风速或降雨量的预测应用中。类似，其也可以满足诸如振动趋势预测、电力负荷预测等工程的实际需要，普适性较强。

十、 参考文献

[1] 赵若男,苏同生,宋瑞,何丽云,宋虎杰,王启桢,吕晓颖.中风队列研究中多重插补法拟合量表缺失数据效果评价[J].中国中医药信息杂志,2022,29(3):110-116

[2] 张文耀.用斯皮尔曼系数衡量网络的度相关[D].中国科学技术大学,2016.Zhang Wenyao. Using Spearman's coefficient to measure the degree correlation of the network [D]. University of Science and Technology of China, 2016.

[3] 叶玉杰. 基于 ARIMA-LSTM 混合模型的短期空气质量预测[D].天津商业大学,2022.DOI:10.27362/d.cnki.gtsxy.2022.000289.

[4] 王纪鹏,黎燕,张阳,李怀亮.基于 ARIMA 模型的邮政业务量预测研究[J].邮政研究,2023,39(02):36-40.DOI:10.13955/j.yzyj.2023.02.07.05.

[5] 徐虎博,史东辉.基于 ARIMA 和 LSTM 模型的建筑安全事故预测[J].软件工程,2023,26(03):9-14.DOI:10.19644/j.cnki.issn2096-1472.2023.003.003.

[6] 向玲,刘佳宁,苏浩,胡爱军,朱泽宁.基于 CEEMDAN 二次分解和 LSTM 的风速多步预测研究[J].太阳能学报,2022,43(08):334-339.DOI:10.19912/j.0254-0096.tynxb.2020-1410.

[7] 张晗. 基于 LSTM 神经网络空气污染监测预报系统的研究与实现[D].西安电子科技大学,2019.DOI:10.27389/d.cnki.gxadu.2019.002766.

附录

附录 1
介绍：支撑材料的文件列表
1. 程序源码 2. 模型的结果与结论 3. 论文 Word 版本

附录 2
介绍：ARIMA 模型对 AQI 预测各过程结果图

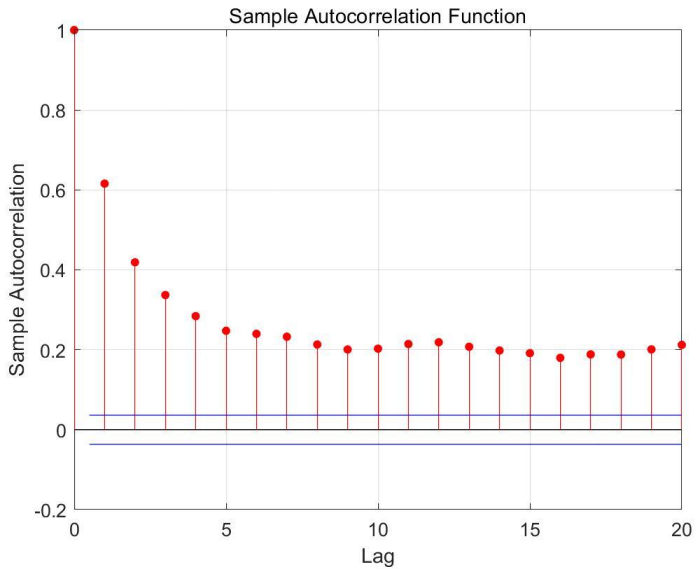

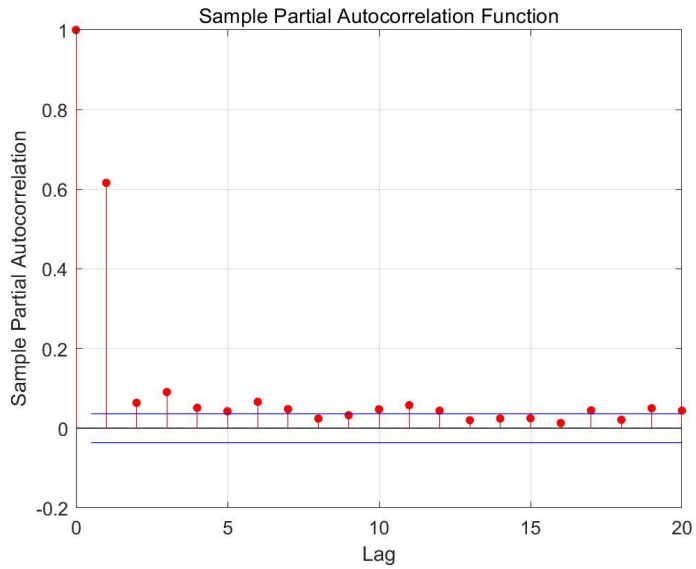

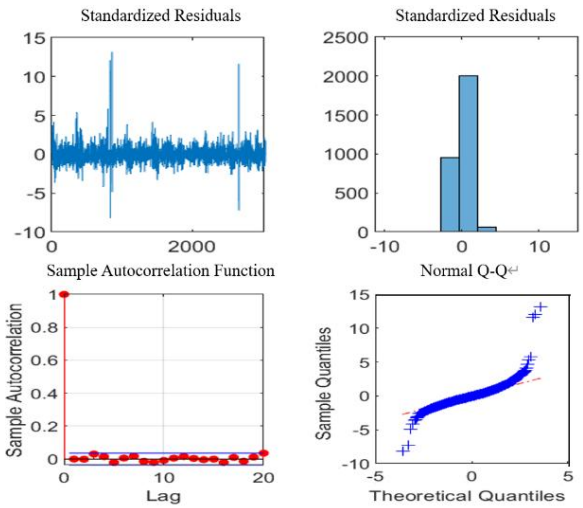

附录 3
介绍：多重插补（SPSS）
第一步：打开 SPSS 第二步：导入数据 第三步：“分析” 第四步：“多重插补” 第五步：“插补缺失数据值” 第六步：“选择变量” 第七步：“确认”

附录 4
介绍：拉格朗日插补（MATLAB）

```
%lagrange insert
function y=lagranges(x0,y0,x)
n=length(x0);m=length(x);
for i=1:m
    z=x(i);
    s=0.0;
    for k=1:n
        p=1.0;
        for j=1:n
            if j~=k
                p=p*(z-x0(j))/(x0(k)-x0(j));
            end
        end
        s=p*y0(k)+s;
    end
    y(i)=s;
end
```

附录 5
介绍：标准化（MATLAB）
x==xlsread（最终整合数据.xls） y=zscore（x）

附录 6
介绍：斯皮尔曼热力图（MATLAB）
data=xlsread（标准化数据.xls） x=corr(data,'type','Spearman') HM=heatmap(x);

附录 7

介绍：ARIMA 模型（MATLAB）

```
Y=load('PM2.5.mat')
plot(Y)

figure
autocorr(Y)
figure
parcorr(Y)
%ACF 和 PACF 图

y_h_adf = adftest(Y)
y_h_kpss = kpsstest(Y)
%平滑性检验,yd1_h_adf =1，yd1_h_kpss =0，通过检验

Yd1 = diff(Y);
% 一阶差分，结果平稳。如果依旧不平稳的话，再次求差分，直至通过检验
yd1_h_adf = adftest(Yd1)
yd1_h_kpss = kpsstest(Yd1)
Yd1=Yd1';
Y=Y';
%Yd2 转换成列向量



LOGL = zeros(4,4); % Initialize
PQ = zeros(4,4);
for p = 1:4
    for q = 1:4
        Mdl = arima(p,1,q);
        [~,~,logL] = estimate(Mdl,Yd1,'Display','off');
        LOGL(p,q) = logL;
        PQ(p,q) = p + q;
```

```
        end
end

LOGL = reshape(LOGL,16,1);
PQ = reshape(PQ,16,1);
[~,bic] = aicbic(LOGL,PQ+1,100);

a=reshape(bic,4,4)
%reshape  重构数组

a_max=max(a(:));
[x,y]=find(a==min(a(:)));

%找最佳 lags 值

Mdl = arima(x, 1, y);   %第二个变量值为 1，即一阶差分
EstMdl = estimate(Mdl,Y);
[res,~,logL] = infer(EstMdl,Y);     %res 即残差

stdr = res/sqrt(EstMdl.Variance);
figure('Name','残差检验')
subplot(2,3,1)
plot(stdr)
title('Standardized Residuals')
subplot(2,3,2)
histogram(stdr,10)
title('Standardized Residuals')
subplot(2,3,3)
autocorr(stdr)
subplot(2,3,4)
parcorr(stdr)
subplot(2,3,5)
qqplot(stdr)
%上图为残差检验的结果图。
% Standardized Residuals 是查看残差是否接近正态分布
% ACF 和 PACF 检验残差的自相关和偏自相关
%  最后一张 QQ 图是检验残差是否接近正太分布的

% Durbin-Watson  统计是计量经济学分析中最常用的自相关度量
diffRes0 = diff(res);
SSE0 = res'*res;
DW0 = (diffRes0'*diffRes0)/SSE0 % Durbin-Watson statistic，

step = 12; %预测步数为 12
```

```
[forData,YMSE] = forecast(EstMdl,step,'Y0',Y);
lower = forData - 1.96*sqrt(YMSE); %95 置信区间下限
upper = forData + 1.96*sqrt(YMSE); %95 置信区间上限

figure()
plot(Y,'Color',[.7,.7,.7]);
hold on
h1 = plot(length(Y):length(Y)+step,[Y(end);lower],'r:','LineWidth',2);
plot(length(Y):length(Y)+step,[Y(end);upper],'r:','LineWidth',2)
h2 = plot(length(Y):length(Y)+step,[Y(end);forData],'k','LineWidth',2);
legend([h1 h2],'95%  置信区间','预测值',...
            'Location','NorthWest')
title('Forecast')
X=3030:1:3041;
plot(X,test,'color',[0.5 0.5 0.5])

hold off
```

附录 8

介绍：LSTM 模型（Python）

```
import seaborn as sns
import pandas as pd
import talos as ta
import numpy as np
from numpy import zeros, newaxis
from matplotlib import pyplot as plt
from joblib import dump, load
from keras.utils.vis_utils import plot_model
from tensorflow import keras
from sklearn.preprocessing import MinMaxScaler, PowerTransformer,StandardScaler
from sklearn.metrics import mean_squared_error, r2_score, max_error,mean_absolute_error
from tensorflow.keras.optimizers import Adam, Nadam
from tensorflow.keras.utils import plot_model
from tensorflow.keras import Sequential, layers, callbacks
from tensorflow.keras.layers import Input, Dense, LSTM, Dropout, GRU,Bidirectional, SimpleRNN, Conv1D, MaxPooling1D, Flatten
from keras.utils.vis_utils import plot_model
from tensorflow import keras
from sklearn.preprocessing import MinMaxScaler, PowerTransformer,StandardScaler
from sklearn.metrics import mean_squared_error, r2_score, max_error,mean_absolute_error
from tensorflow.keras.optimizers import Adam, Nadam
from tensorflow.keras.utils import plot_model
```

```
from tensorflow.keras import Sequential, layers, callbacks
from tensorflow.keras.layers import Input, Dense, LSTM, Dropout, GRU,Bidirectional,
SimpleRNN, Conv1D, MaxPooling1D, Flatten
df = pd.read_csv('data.csv',index_col='序号')
#df.sort_index(inplace=True)
#df.dropna(inplace=True)
data = df
data.info
plt.figure(figsize=(15, 6))
plt.subplots_adjust(top=1.25, bottom=1.2)
data['PM2.5'].plot()
plt.ylabel('Adj Close')
plt.xlabel(None)
plt.title("Closing PM2.5 of Stock")
plt.tight_layout()
data = data.filter(['PM2.5'])
dataset = data.values
training_data_len = int(np.ceil(2400))
from sklearn.preprocessing import MinMaxScaler
scaler = MinMaxScaler(feature_range=(0,1))
scaled_data = scaler.fit_transform(dataset)
train_data = scaled_data[0:int(training_data_len), :]
x_train = []
y_train = []
for i in range(60, len(train_data)):
    x_train.append(train_data[i-60:i, 0])
    y_train.append(train_data[i, 0])
x_train, y_train = np.array(x_train), np.array(y_train)
x_train = np.reshape(x_train, (x_train.shape[0], x_train.shape[1], 1))
test_data = scaled_data[training_data_len - 60: , :]
x_test = []
y_test = dataset[training_data_len:, :]
for i in range(60, len(test_data)):
    x_test.append(test_data[i-60:i, 0])
x_test = np.array(x_test)
x_test = np.reshape(x_test, (x_test.shape[0], x_test.shape[1], 1))

import tensorflow as tf
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, LSTM
tf.random.set_seed(1234)
model = Sequential()
model.add(LSTM(128, return_sequences=True, input_shape=
(x_train.shape[1],1)))
```

```
model.add(LSTM(64, return_sequences=False))
model.add(Dense(25))
model.add(Dense(1))
lr_schedule = tf.keras.optimizers.schedules.ExponentialDecay(
initial_learning_rate=1e-2,
decay_steps=1427,
decay_rate=0.9)
opt = tf.keras.optimizers.Adam(learning_rate = lr_schedule)
model.compile(optimizer=opt, loss='mean_squared_error')
model.fit(x_train, y_train, batch_size=16, epochs=5)
predictions_lstm = model.predict(x_test)
predictions_lstm = scaler.inverse_transform(predictions_lstm)
rmse_ltsm = np.sqrt(np.mean(((predictions_lstm - y_test) ** 2)))
print("LSTM model rmse rate：{}".format(rmse_ltsm))
plt.figure(figsize=(15, 6))
plt.plot(predictions_lstm, label="Predict PM2.5")
plt.plot(y_test, label="Real PM2.5")
plt.title("LSTM Model")
plt.xlabel("Time")
plt.ylabel("PM2.5")
plt.legend()
plt.show()
n_steps=60
future_data = dataset[-n_steps:, 0]   # 获取最后 n_steps 天的数据作为输入
for i in range(12):
    future_data_input = future_data[-n_steps:].reshape(1, n_steps, 1)
    future_pred = model.predict(future_data_input)
    future_data = np.append(future_data, future_pred)
    future_pred = scaler.inverse_transform(future_pred)
    print(future_pred)

# 将未来数据与原始数据合并
future_data = future_data[n_steps:].reshape(-1, 1)
future_data = scaler.inverse_transform(future_data)

pred_size = np.size(future_data)
print(pred_size)

print("predict number:\n",future_pred)
print("future data:\n",future_data)

data = scaler.inverse_transform(data)
merged_data = np.concatenate((data, future_data), axis=0)
# 绘制数据图表
```

```
plt.plot(merged_data)
plt.show()
```

附录 9
介绍：因素折线图（Python）

```
import pandas as pd
from matplotlib import pyplot as plt
import numpy as np
df = pd.read_csv('data.csv',index_col='序号')
data = df
data.info
plt.figure(figsize=(15, 6))
plt.subplots_adjust(top=1.25, bottom=1.2)
data['name'].plot() #自定义 name 为某个因素的名称
plt.ylabel('Adj Close')
plt.xlabel(None)
plt.title("Closing name of Stock")
plt.tight_layout()
```